




Come Funziona Salmon: Dal Trascrittoma alla Stima di Abbondanza


Fase 1: Indicizzazione del Trascrittoma




Trascrittoma di Riferimento (FASTA)

Creazione di un indice per una ricerca ultra-veloce

1. Scomposizione in k-meri



2. Costruzione delle strutture dati




L'indice si costruisce una sola volta.
Processo computazionalmente intensivo, eseguito una volta e riutilizzato per innumerevoli campioni.

Fase 2: Quantificazione e Algoritmo EM

Conteggio iniziale delle reads tramite "quasi-mapping"

Reads del Campione



Processo dei k-meri




:

Per ogni read, Salmon identifica i k-meri e usa l'indice per trovare rapidamente i trascritti compatibili, determinando solo potenziale origine, posizione e orientamento.

L'algoritmo EM risolve l'ambiguità

Processo iterativo che stima la frazione più probabile di reads ambigue da assegnare a ciascun trascritto.

Esempio pratico dell'algoritmo EM (2 trascritti, 5 reads, Read 5 ambigua)



Iterazione 1 (Passo E): Assegnazione iniziale

Read 5 $\xrightarrow{50/50}$ 50/50

Conteggio T1: 3 (uniche) + 0.5 (R5) = 3.5
Conteggio T2: 1 (unica) + 0.5 (R5) = 1.5

Iterazione 1 (Passo M): Stima dell'abbondanza

Abbondanza T1 (p_1): 3.5 / 5 reads = 0.7 (70%)
Abbondanza T2 (p_2): 1.5 / 5 reads = 0.3 (30%)

Iterazione 2 (Passo E): Ri-assegnazione pesata

Read 5 $\xrightarrow{50/50}$ 70/30

Conteggio T1: 3 + 0.7 (R5) = 3.7
Conteggio T2: 1 + 0.3 (R5) = 1.3


Iterazione 2 (Passo M): Nuova stima di abbondanza

Abbondanza T1 (p_1): 3.7 / 5 = 0.74 (74%)
Abbondanza T2 (p_2): 1.3 / 5 = 0.26 (28%)

Il processo continua fino alla convergenza, finché le stime di abbondanza non si stabilizzano.


Fase 3: Correzione dei Bias Sperimentali

I dati RNA-seq non sono perfetti




Errori sistematici (bias) durante preparazione e sequenziamento alterano le stime di abbondanza.


Tipi di bias corretti da Salmon



Bias di sequenza
(preferenza estremità 5'/3')



Bias del contenuto di GC
(sotto/sovrerappresentazione di alto/basso GC)



Bias posizionale
(probabilità di campionamento varia lungo il trascritto)

Come avviene la correzione?



Salmon apprende modelli di bias dai dati e calcola una "lunghezza effettiva corretta" per ogni trascritto, tenendo conto della probabilità reale di sequenziamento.

Stime più accurate e maggiore sensibilità.
Migliora l'accuratezza e aumenta la potenza statistica per analisi a valle come l'identificazione di geni differenzialmente espressi.